

Optimalisasi Prediksi Penyakit Jantung melalui Integrasi *Klustering* dan Klasifikasi: Pendekatan Berbasis *Machine Learning*

Seriusman Waruwu¹, Zaskhia Artina Isnalifah²

^{1,3} Teknik Informatika, Universitas Negeri Surabaya

125051905004@mhs.unesa.ac.id

225051905016@mhs.unesa.ac.id

Abstrak— Penyakit kardiovaskular (PKV) merupakan penyebab kematian utama secara global, namun sistem diagnostik klinis konvensional seringkali terkendala oleh tingginya heterogenitas faktor risiko pasien dan kompleksitas data medis. Penelitian ini mengusulkan kerangka kerja hibrida terpadu yang mengintegrasikan segmentasi risiko klinis *unsupervised* dan klasifikasi *supervised* untuk meningkatkan presisi deteksi dini PKV. Pendekatan yang diusulkan diawali dengan tahap pra-pemrosesan menggunakan algoritma *K-Means* untuk mengelompokkan 918 data rekam medis gabungan ke dalam tiga kluster profil risiko (rendah, moderat, dan kritis). Selanjutnya, tiga algoritma (*XGBoost*, *Random Forest*, dan *Logistic Regression*) dievaluasi secara komparatif sebagai mekanisme seleksi fitur menggunakan *Recursive Feature Elimination* (RFE) dan sebagai model klasifikasi utama. Hasil pengujian membuktikan bahwa *Logistic Regression* mencapai performa paling optimal untuk kebutuhan medis dengan tingkat Akurasi 89,67%, *Recall* 92,16%, dan *F1-Score* 90,82%, sehingga sangat efektif dalam meminimalisasi *false negatives*. Untuk mengatasi sifat *black-box* algoritma, analisis *SHapley Additive exPlanations* (SHAP) diintegrasikan dan berhasil memvalidasi bahwa atribut kemiringan segmen ST (*ST_Slope_Up*) serta tipe nyeri dada (*ChestPainType_ASY*) merupakan prediktor paling determinan secara klinis. Seluruh arsitektur model ini diimplementasikan ke dalam antarmuka *web* interaktif berbasis *Streamlit*, menghasilkan sistem pendukung keputusan klinis (CDSS) yang akurat, transparan, dan adaptif terhadap variasi kondisi pasien individual.

Kata Kunci— Penyakit Kardiovaskular, *Machine Learning* Hibrida, *K-Means Clustering*, Seleksi Fitur, SHAP, *Streamlit*.

I. PENDAHULUAN

Penyakit kardiovaskular (PKV) hingga saat ini tetap menjadi penyebab kematian utama di seluruh dunia. Berdasarkan data *Global Burden of Disease* (GBD), PKV bertanggung jawab atas 19,2 juta kematian pada tahun 2023, meningkat signifikan dari 13,1 juta kematian pada tahun 1990[1], [2]. Pada tahun yang sama, sebesar 79,6% dari seluruh *disability-adjusted life years* (DALYs) akibat PKV secara global dapat dikaitkan dengan faktor risiko yang dapat dimodifikasi, dengan faktor metabolik seperti indeks massa tubuh tinggi dan glukosa plasma puasa tinggi menjadi kontributor terbesarnya. Di Indonesia sendiri, data WHO menyebutkan 17,8 juta orang meninggal setiap tahun akibat penyakit jantung di seluruh dunia, dan Indonesia termasuk negara dengan prevalensi penyakit kardiovaskular tertinggi[3]. Kondisi ini menegaskan bahwa deteksi dini dan manajemen risiko proaktif merupakan strategi intervensi yang paling kritis

untuk menekan angka mortalitas dan beban ekonomi sektor kesehatan[1][2].

Namun, sistem diagnostik klinis konvensional menghadapi keterbatasan mendasar dalam memenuhi tuntutan tersebut. Model prediksi risiko tradisional seringkali gagal menangkap sifat multifaset dari faktor risiko PKV maupun memanfaatkan kumpulan data rekam medis elektronik yang terus berkembang secara optimal[4]. Permasalahan ini diperparah oleh tingginya heterogenitas profil klinis pasien PKV, yang ditandai oleh kombinasi variabel risiko yang sangat kompleks—mulai dari usia, tekanan darah, kadar kolesterol, hingga riwayat metabolik. Tantangan utama dalam diagnostik PKV terletak pada kompleksitas data klinis serta proses seleksi dan pemodelan fitur yang berguna, sehingga sulit mencapai akurasi dan keandalan yang tinggi tanpa strategi pemilihan fitur yang tepat [5].

Pemilihan fitur (*feature selection*) merupakan tahapan krusial yang secara langsung menentukan performa model prediksi. Prediksi penyakit jantung yang paling akurat diperoleh melalui pendekatan *feature selection*, di mana algoritma seperti *Logistic Regression*, *Random Forest*, dan *XGBoost* digunakan bersama-sama dalam model hibrida untuk membangun prediksi yang optimal[6]. Sebuah studi pada model prediksi PKV berbasis *XGBoost* menunjukkan bahwa penggabungan seleksi fitur ganda melalui koefisien korelasi Pearson dan peringkat *feature importance* secara signifikan meningkatkan performa model dibandingkan algoritma konvensional seperti *Logistic Regression*, SVM, *Random Forest*, dan KNN[7].

Mengidentifikasi subset fitur paling informatif, tiga algoritma klasifikasi *XGBoost*, *Random Forest*, dan *Logistic Regression* dapat dimanfaatkan secara komparatif sebagai mekanisme pemilihan fitur. Pada studi komparatif menggunakan dataset UCI dan IEEE DataPort, *Random Forest* mencapai akurasi tertinggi sebesar 94% (*K=10 cross-validation*), *XGBoost* sebesar 93%, dan keduanya menunjukkan nilai ROC-AUC tertinggi pada 95% dan 94% secara berurutan, sementara *Logistic Regression* berperan sebagai *baseline* interpretabel yang stabil [8]. Pada konteks lain, *XGBoost* menunjukkan performa prediksi tertinggi dengan akurasi pelatihan 97,12% dan nilai AUC 0,91, sedangkan *Random Forest* mencatatkan AUC tertinggi sebesar 0,92, menegaskan keunggulan metode *ensemble* dibandingkan pendekatan linier[9].

Guna mengatasi permasalahan heterogenitas variabel pasien, sejumlah penelitian telah mengusulkan pendekatan klasterisasi sebagai tahap pra-pemrosesan. Metode hibrida yang mengintegrasikan K-Means *clustering* dengan *Random Forest classifier* berhasil mencapai akurasi diagnosis penyakit jantung sebesar 96,8%, mengungguli metode konvensional secara signifikan, karena klasterisasi memungkinkan algoritma klasifikasi berfokus pada pola sub-populasi yang lebih homogen[10]. Senada dengan itu, penerapan klasterisasi berbasis *k-modes* sebagai tahap pra-pemrosesan terbukti meningkatkan akurasi seluruh algoritma yang diuji, dengan semua model melampaui ambang akurasi 86% pada dataset kardiovaskular berskala besar dengan 70.000 instans[11].

Berdasarkan celah penelitian di atas, studi ini mengusulkan arsitektur hibrida yang mengintegrasikan K-Means untuk segmentasi risiko klinis dengan tiga algoritma klasifikasi *supervised* XGBoost, *Random Forest*, dan *Logistic Regression* yang dijalankan secara komparatif sebagai mekanisme seleksi fitur. Ketiga model dilatih pada subset fitur yang sama, kemudian fitur-fitur dengan kontribusi tertinggi terhadap akurasi dipilih berdasarkan model yang menghasilkan performa terbaik. Pendekatan ini sejalan dengan praktik terbaik dalam literatur, di mana teknik *feature selection* seperti *Random Forest Importance*, LASSO, dan *Information Gain* dikombinasikan dengan evaluasi komparatif berbagai algoritma klasifikasi untuk mengidentifikasi subset fitur yang paling optimal [11]. Integrasi ini diharapkan menghasilkan sistem deteksi dini penyakit jantung yang lebih akurat, presisi, dan adaptif terhadap heterogenitas faktor risiko individu.

II. TINJAUAN PUSTAKA

Berdasarkan permasalahan dan tujuan penelitian yang telah diuraikan pada Bab I, Bab ini menyajikan tinjauan pustaka yang relevan sebagai kerangka konseptual penelitian. Tinjauan ini meliputi studi terdahulu mengenai prediksi penyakit kardiovaskular berbasis *machine learning*, pendekatan klasterisasi K-Means untuk segmentasi profil risiko pasien, serta kajian komparatif algoritma XGBoost, *Random Forest*, dan *Logistic Regression* dalam konteks klasifikasi klinis dan seleksi fitur. Pemahaman terhadap penelitian-penelitian yang telah ada menjadi pijakan untuk mengidentifikasi celah (*research gap*) yang dijawab oleh penelitian ini.

A. Penyakit Jantung dan Urgensi Deteksi Dini

Penyakit jantung merupakan kondisi patologis akibat gangguan struktural maupun fungsional pada organ jantung, mencakup penyakit jantung koroner, gagal jantung, aritmia, kardiomiopati, hingga infark miokardium. Penyakit jantung menjadi tantangan kesehatan global yang signifikan karena berbagai pendekatan deteksi yang ada masih memiliki celah, sehingga kebutuhan terhadap metode prediksi yang lebih akurat dan efektif menjadi semakin kritis[12]. Kondisi ini diperparah oleh sifat asimtomatik penyakit jantung pada stadium awal dan tingginya heterogenitas profil klinis pasien mencakup kombinasi variabel usia, tekanan darah, kadar kolesterol, hingga riwayat metabolik yang menyulitkan model

klasifikasi konvensional dalam menghasilkan prediksi yang presisi. Integrasi machine learning (ML) menawarkan solusi transformatif, di mana model prediksi berbasis ML telah terbukti mampu mengoperasionalisasi skor risiko klinis, memprediksi waktu onset penyakit jantung, dan memperkirakan prognosis pasien secara individual[13].

B. Algoritma K-Means untuk Segmentasi Risiko Klinis

K-Means merupakan algoritma *clustering* tak terawasi yang mengelompokkan data ke dalam k kluster berdasarkan kemiripan jarak Euclidean antara titik data dan centroid kluster. Penerapan K-Means bersama metode reduksi dimensi pada dataset klinis kardiovaskular berhasil mengidentifikasi kelompok pasien dengan tingkat risiko yang berbeda berdasarkan variabel seperti usia, tekanan darah, kadar glukosa, dan troponin, termasuk mengungkap profil risiko tinggi yang tidak terdeteksi oleh model *supervised* [7]. Di antara 117 metode *clustering* yang ditinjau dalam literatur medis, K-Means merupakan metode *unsupervised* yang paling banyak digunakan (40,2%), termasuk untuk deteksi subkelompok penyakit arteri koroner [14].

Dalam konteks pra-pemrosesan, K-Means terbukti meningkatkan kualitas data masukan untuk model klasifikasi. Model hibrida XGBoost–K-Means yang diuji pada dataset UCI Cleveland menghasilkan akurasi 93,8%, presisi 92,4%, recall 93,1%, F1-score 92,7%, dan AUC-ROC 0,96—mengungguli baseline seperti *Logistic Regression*, *Naive Bayes*, dan *Random Forest* sebesar 5–6% dalam hal akurasi [15].

C. XGBoost

XGBoost (*Extreme Gradient Boosting*) adalah algoritma *ensemble* berbasis *gradient boosting* yang secara sekuensial membangun model prediksi, di mana setiap pohon keputusan baru dilatih untuk mengoreksi *error* dari pohon sebelumnya dengan dukungan regularisasi, pemrosesan paralel, dan penanganan data hilang secara efisien [16]. Berkat kemampuannya dalam memproses data heterogen dengan akurasi dan skalabilitas tinggi, XGBoost saat ini sangat diandalkan dalam tugas klasifikasi medis, khususnya untuk mendeteksi dan mengklasifikasikan risiko penyakit jantung, karena model ini mampu menghasilkan prediksi yang presisi sekaligus mempertahankan interpretabilitas yang esensial untuk mendukung pengambilan keputusan klinis [17].

D. Random Forest

Random Forest (RF) merupakan algoritma *ensemble* yang membangun sekumpulan *decision tree* secara paralel menggunakan subset data dan fitur secara acak, yang kemudian menggabungkan hasil prediksinya melalui mekanisme *majority voting* [18]. Proses randomisasi ini secara signifikan mampu meningkatkan kemampuan generalisasi model dan meminimalisasi risiko *overfitting*, menjadikannya sangat tangguh (*robust*) saat menangani data medis yang bising (*noisy*) atau memiliki banyak nilai yang hilang (*missing values*). Berkat keandalan dan akurasinya yang konsisten, RF saat ini diaplikasikan secara luas dalam sistem prediksi klinis, khususnya diakui sebagai salah satu metode *machine learning*

yang paling efektif untuk memprediksi dan mengklasifikasikan risiko penyakit jantung berdasarkan profil rekam medis pasien yang kompleks[19].

E. Logistic Regression

Logistic Regression (LR) adalah algoritma klasifikasi parametrik yang memodelkan probabilitas luaran biner menggunakan fungsi sigmoid, di mana koefisien modelnya disesuaikan secara iteratif melalui *maximum likelihood estimation* untuk meminimalisasi selisih antara probabilitas prediksi dan nilai aktual [20]. Secara khusus, algoritma ini secara ekstensif digunakan untuk memprediksi dan mengklasifikasikan risiko penyakit jantung karena kemampuannya yang luar biasa dalam mengevaluasi dan memetakan bobot kontribusi dari setiap variabel klinis pasien secara transparan, sehingga sangat mendukung pengambilan keputusan medis yang berbasis bukti klinis[21].

F. Penelitian Terdahulu dan Posisi Penelitian ini

Kajian penelitian terdahulu dilakukan untuk mengetahui perkembangan metode prediksi penyakit jantung berbasis machine learning, khususnya yang terkait dengan klasterisasi, klasifikasi dan seleksi fitur. Dari berbagai penelitian yang telah dipublikasikan, cenderung penelitian hanya mengoptimalkan salah satu aspeknya seperti klasterisasi saja, klasifikasi saja atau seleksi fitur saja tanpa integrasi dari ketiganya. Sehingga pada Tabel 1 merangku penelitian terkini dan relevan untuk mengidentifikasi celah penelitian sebagai fundamental dari penelitian ini.

TABEL I
PENELITIAN TERDAHULU

Penulis	Dataset	Metode	Akurasi Terbaik	Celah (Gap)
[22], 2024	UCI Cleveland	K-Means + Random Forest (K-RFC)	96,8%	Tanpa seleksi fitur dan hanya satu algoritma klasifikasi
[8], 2025	UCI Cleveland + Statlog	RF, KNN, LR, NB, GB, AdaBoost, XGBoost	RF: 94%, XGB: 90%	Tanpa algoritma klasterisasi sebagai pra-pemrosesan
[12], 2024	UCI + Dataset Pribadi	KNN, SVM, LR, CNN, GB, XGBoost, RF	XGBoos t: 98,50%	Tanpa algoritma klasterisasi; dan seleksi fitur
[7], 2024	Dataset CVD 70.000 instans	XGBoost + Seleksi Fitur Ganda (Pearson + Feature Importanc e)	97,6%	Hanya satu algoritma klasifikasi dan tanpa segmentasi pasien berbasis clustering
[15], 2025	UCI Cleveland	XGBoost + K-	93,8%	Tidak membanding

		Means		kan seleksi fitur antar tiga model; LR dan RF hanya sebagai baseline
--	--	-------	--	--

Berdasarkan analisis literatur terdahulu, terdapat beberapa celah utama dalam pengembangan model prediksi penyakit jantung yang belum diselesaikan secara simultan. Untuk menjawab batasan tersebut, kebaruan (*novelty*) dari penelitian ini mengusulkan kerangka kerja hibrida terpadu (*integrated clustering–feature selection–classification framework*) pada dataset UCI Cleveland melalui arsitektur dua tahap: segmentasi risiko klinis berbasis K-Means untuk pra-pemrosesan yang dilanjutkan dengan klasifikasi *supervised*.

Secara fundamental, model XGBoost, *Random Forest*, dan *Logistic Regression* tidak sekadar difungsikan sebagai prediktor, tetapi dijalankan secara paralel sebagai instrumen seleksi fitur komparatif guna mengekstraksi fitur paling optimal dan menghilangkan bias algoritma tunggal. Keandalan arsitektur ini kemudian divalidasi secara menyeluruh melalui evaluasi multi-metrik (akurasi, presisi, *recall*, *F1-score*, dan *AUC-ROC*) untuk memastikan model yang dihasilkan benar-benar *robust* dalam mendukung deteksi dini penyakit jantung di lingkungan klinis.

III. METODOLOGI PENELITIAN

Metodologi dalam penelitian ini dirancang untuk menjawab tantangan deteksi dini penyakit jantung melalui pendekatan komputasional yang terstruktur. Bab ini membahas secara rinci alur penelitian yang meliputi eksplorasi dan persiapan data, perancangan skenario eksperimen, penerapan algoritma *machine learning*, hingga tahap evaluasi kinerja dan interpretabilitas model. Seluruh tahapan ini disusun untuk memastikan bahwa model yang dikembangkan tidak hanya akurat, tetapi juga valid dan dapat dijelaskan secara medis.

A. Pengumpulan dan Deskripsi Data

Penelitian ini menggunakan dataset sekunder yang merupakan gabungan dari lima sumber data penyakit jantung, yaitu Cleveland, Hungarian, Switzerland, Long Beach VA, dan Stalog. Penggabungan ini bertujuan untuk membentuk kumpulan data yang lebih komprehensif guna memprediksi kemungkinan penyakit kardiovaskular. Dari total 1190 observasi awal yang terkumpul, dilakukan proses pembersihan untuk menghapus 272 data duplikat. Hasil akhir dari proses ini adalah dataset final yang terdiri dari 918 observasi yang siap untuk diproses lebih lanjut. Dataset ini mencakup 11 fitur prediktor yang merepresentasikan kondisi medis pasien serta 1 label target. Rincian dari masing-masing variabel dapat dilihat pada Tabel II.

TABEL III
DESKRIPSI VARIABEL DATASET

Variabel	Tipe Data	Deskripsi Singkat
Age	Numerik	Usia pasien (dalam tahun).
Sex	Kategorikal	Jenis kelamin (M: Laki-laki, F: Perempuan).
ChestPainType	Kategorikal	Tipe nyeri dada (TA, ATA, NAP, ASY).
RestingBP	Numerik	Tekanan darah saat istirahat (mm Hg).
Cholesterol	Numerik	Kadar kolesterol serum (mm/dl).
FastingBS	Kategorikal	Gula darah puasa (1 jika > 120 mg/dl, 0 jika tidak).
RestingECG	Kategorikal	Hasil EKG saat istirahat (Normal, ST, LVH).
MaxHR	Numerik	Detak jantung maksimum yang dicapai.
ExerciseAngina	Kategorikal	Angina akibat olahraga (Y: Ya, N: Tidak).
Oldpeak	Numerik	Depresi ST akibat olahraga relatif terhadap istirahat.
ST_Slope	Kategorikal	Kemiringan segmen ST (Up, Flat, Down).
HeartDisease	Target	Indikasi penyakit (1: Positif sakit, 0: Normal).

A. Eksplorasi dan Pra-pemrosesan Data

Data akan melalui tahapan *Exploratory Data Analysis* (EDA), sebelum dilanjutkan ke tahapan permodelan. Analisis ini mencakup perhitungan ringkasan statistik dasar, pengamatan distribusi data melalui histogram, dan deteksi nilai ekstrem (pencilan) menggunakan visualisasi *boxplot*. Hubungan antar variabel, termasuk korelasinya terhadap label target, juga dievaluasi menggunakan *heatmap* matriks korelasi untuk mengidentifikasi pola awal.

Langkah selanjutnya adalah pra-pemrosesan data, yang sangat krusial mengingat algoritma *machine learning* memiliki sensitivitas tinggi terhadap skala dan anomali data. Tahapan ini diawali dengan penanganan *missing values* serta penghapusan data yang tidak valid secara medis, seperti nilai tekanan darah atau kolesterol yang bernilai nol. Selanjutnya, transformasi variabel kategorikal dilakukan dengan menerapkan *Label Encoding* untuk data bertingkat (ordinal) dan *One-Hot Encoding* untuk data nominal. Terakhir, agar seluruh fitur numerik berada pada skala yang seragam, dilakukan proses standarisasi menggunakan metode *StandardScaler* sehingga data memiliki rata-rata nol dan standar deviasi satu.

B. Permodelan Data

Untuk mengevaluasi dampak jumlah fitur terhadap efisiensi komputasi dan performa model, penelitian ini merancang dua skenario eksperimen. Skenario A bertindak sebagai garis dasar (*baseline*), di mana seluruh 11 fitur yang telah melewati tahap pra-pemrosesan langsung digunakan dalam proses klastering dan klasifikasi. Di sisi lain, Skenario B menerapkan metode

seleksi fitur menggunakan kombinasi pendekatan Filter (membuang fitur dengan korelasi terendah) dan pendekatan *Wrapper* berupa *Recursive Feature Elimination* (RFE). Melalui Skenario B, hanya 5 hingga 7 fitur paling berpengaruh yang akan dipertahankan untuk meminimalkan beban komputasi tanpa mengorbankan akurasi secara signifikan.

C. Segmentasi Pasien (Klastering)

Data mengalami heterogenitas sehingga untuk mengatasi kondisi tersebut maka dilakukan pendekatan *unsupervised learning* diterapkan sebelum proses klasifikasi utama. Jika diperlukan, *Principal Component Analysis* (PCA) digunakan terlebih dahulu untuk mereduksi dimensi data guna mempermudah visualisasi kelompok. Penentuan jumlah klaster optimal (K) dicari menggunakan pengujian *Elbow Method* dan *Silhouette Score*.

Proses segmentasi diimplementasikan menggunakan tiga algoritma yang berjalan secara paralel untuk dibandingkan: K-Means untuk pencarian sentroid yang solid, DBSCAN untuk mengelompokkan kepadatan data dan mengisolasi *noise*, serta *Gaussian Mixture Model* (GMM) untuk pengelompokan berbasis probabilitas distribusi. Model klastering yang menghasilkan skor evaluasi terbaik akan dipilih, dan label kelompoknya diekstrak menjadi satu fitur baru bernama Cluster ID. Fitur ini kemudian digabungkan kembali ke dalam dataset utama untuk memberikan konteks profil risiko pasien.

D. Klasifikasi dan Evaluasi Model

Dataset yang telah terintegrasi dengan fitur segmentasi (hasil klastering K-Means) kemudian dipisahkan menjadi data latih dan data uji. Berdasarkan celah penelitian terkait penanganan data medis yang kompleks, studi ini mengusulkan arsitektur hibrida yang mengintegrasikan K-Means untuk segmentasi risiko klinis dengan tiga algoritma klasifikasi supervised learning, yaitu XGBoost, Random Forest, dan Logistic Regression.

Ketiga algoritma klasifikasi ini tidak hanya digunakan untuk prediksi, tetapi juga dijalankan secara komparatif sebagai mekanisme seleksi fitur. Dalam penerapannya, ketiga model dilatih pada subset fitur yang sama, kemudian fitur-fitur dengan kontribusi tertinggi terhadap akurasi dipilih berdasarkan model yang menghasilkan performa terbaik. Pendekatan ini sejalan dengan praktik terbaik dalam literatur, di mana teknik *feature selection* seperti Random Forest Importance dikombinasikan dengan evaluasi komparatif dari berbagai algoritma klasifikasi untuk mengidentifikasi subset fitur yang paling optimal [11]. Integrasi komprehensif ini diharapkan mampu menghasilkan sistem deteksi dini penyakit jantung yang lebih akurat, presisi, dan adaptif terhadap tingginya heterogenitas faktor risiko individu.

E. Analisis SHAP untuk Interpretabilitas Model

Untuk mengatasi kelemahan algoritma seperti XGBoost, Random Forest dan Logistic Regression yang sering dianggap sebagai *black-box*, penelitian ini mengintegrasikan analisis

SHapley Additive exPlanations (SHAP). Berbasis pada teori permainan kooperatif, SHAP memberikan penjelasan yang transparan mengenai keputusan klasifikasi model dengan menghitung kontribusi marginal setiap fitur terhadap prediksi akhir. Nilai Shapley untuk setiap fitur medis dirumuskan secara matematis sebagai berikut:

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)] \quad (1)$$

Keterangan Variabel:

- ϕ_i : Nilai *Shapley* (kontribusi) untuk fitur ke- i .
- N : Himpunan semua fitur.
- S : Sub-himpunan dari fitur yang tidak menyertakan fitur ke- i .
- $|S|$: Jumlah fitur dalam sub-himpunan S .
- $|N|$: Total keseluruhan fitur.
- $v(S \cup \{i\}) - v(S)$: Kontribusi marginal dari fitur ke- i saat ditambahkan ke model yang sudah memiliki sub-himpunan fitur S .

Melalui plot SHAP, penelitian ini tidak hanya akan menyajikan model dengan metrik prediksi tertinggi, tetapi juga memberikan justifikasi klinis yang dapat diinterpretasikan mengenai seberapa besar dorongan variabel tertentu (misalnya tingkat kolesterol atau usia) terhadap peningkatan probabilitas diagnosis penyakit kardiovaskular pada masing-masing individu.

F. Implementasi Antarmuka Pengguna (GUI)

Tahap akhir metodologi, semua *pipeline* model yang telah dibangun menggunakan bahasa pemrograman Python di lingkungan Jupyter Notebook diintegrasikan ke dalam antarmuka web interaktif menggunakan *framework* Streamlit. Antarmuka ini dirancang untuk menjembatani kompleksitas analitik *machine learning* dengan kepraktisan klinis, yang menstrukturkan alur sistem ke dalam lima modul utama yang saling terintegrasi.

Modul pertama dirancang untuk menyajikan landasan konteks penelitian, menampilkan statistik urgensi penyakit kardiovaskular global, serta memberikan deskripsi awal mengenai dimensi dataset gabungan dan informasi 11 atribut medis yang digunakan. Selanjutnya, Modul kedua difungsikan untuk memvalidasi kualitas data secara transparan. Sistem diprogram untuk menampilkan visualisasi distribusi data historis, *heatmap* korelasi, deteksi *outlier*, serta metrik *dataframe* yang telah melalui tahap pra-pemrosesan (standarisasi dan *encoding*).

Modul ketiga dan keempat berfungsi sebagai dashboard interaktif. Dimana modul ketiga akan menampilkan hasil segmentasi pasien. Pengguna dapat memilih skenario

algoritma klustering dan mengevaluasi visualisasi penentuan jumlah kluster optimal (*Elbow Method* atau *Silhouette Score*). Antarmuka akan merender plot sebaran data menggunakan PCA 2D beserta tabel agregasi karakteristik klinis dari setiap kluster. Sedangkan, modul keempat berfokus pada komparasi performa *supervised learning*. Sistem memvisualisasikan perbandingan metrik evaluasi komprehensif (Akurasi, Presisi, Recall, dan F1-Score) antar algoritma klasifikasi. Evaluasi ini juga didukung oleh tayangan *Confusion Matrix* untuk memperlihatkan proporsi tebakan model secara transparan.

Modul kelima adalah modul terakhir yang menjadi inti dari seluruh tahapan analitik, modul ini menyediakan formulir input data rekam medis pasien baru. Berdasarkan parameter klinis yang dimasukkan pengguna, *backend* akan mengeksekusi model *machine learning* secara *real-time*. Modul ini bertugas menghasilkan keluaran berupa probabilitas prediksi penyakit, pemetaan pasien ke dalam segmentasi kluster risiko, serta *generate* peringatan dini dan rekomendasi tindakan medis dasar secara otomatis.

IV. HASIL DAN PEMBAHASAN

Bab ini menguraikan secara komprehensif hasil dari serangkaian eksperimen yang telah dirancang pada tahapan metodologi. Pembahasan difokuskan pada analisis temuan data kuantitatif, kinerja komparatif skenario algoritma, interpretasi justifikasi klinis dari model, hingga hasil akhir berupa pengujian antarmuka sistem prediksi cerdas berbasis web.

A. Hasil Pengumpulan dan Deskripsi Data

Proses konsolidasi dari lima sumber data penyakit jantung (Cleveland, Hungarian, Switzerland, Long Beach VA, dan Stalog) berhasil menyatukan informasi rekam medis pasien yang sangat representatif. Tinjauan menyeluruh (overview) terhadap data awal memperlihatkan sekumpulan atribut klinis yang mengukur rekam jejak kardiometabolik dasar, mulai dari tanda-tanda vital seperti tekanan darah dan detak jantung, hingga hasil uji laboratorium seperti kolesterol dan gula darah. Setelah dilakukan proses penyaringan data kosong dan penghapusan 272 observasi duplikat, diperoleh dataset final sebanyak 918 observasi unik yang valid. Gambaran mengenai struktur data beserta fitur-fitur klinis yang tersisa setelah tahap pembersihan awal ini dapat dilihat pada Gbr 1.

Gbr. 1 — Overview Dataset


Attribute	Value	Age	Sex	Cholesterol	FastingBS	Diabetes	FastingBS	FastingBS	HeartD	
Amelia	918	0	40	M	235	1.80	200	0	Normal	172
Observed		0	40	F	160	1.80	200	0	Normal	256
Amelia_Fiber	11	0	37	M	210	1.80	200	0	ST	86
Predictor		0	40	F	160	1.80	200	0	Normal	208
Label Target	HeartDisease (0/1)	0	34	M	160	1.80	200	0	Normal	123
Sumber	Cleveland, Hungarian, Switzerland, Long Beach VA, Stalog	0	30	M	160	1.80	200	0	Normal	170
Missing Values	0 (kolesterol 0 dikompas)	0	40	F	210	1.80	200	0	Normal	140
		0	37	M	160	1.80	200	0	Normal	130
		0	40	F	210	1.80	200	0	Normal	120

Gbr. 1 — Capaian dataset hasil merge 5 dataset dari 11 fitur dengan atribut prediksi awal.

Gbr 1. Overview dataset rekam medis yang menampilkan sebagian dari 918 observasi dan 11 fitur klinis setelah proses pembersihan awal.

Berdasarkan sampel data yang disajikan pada Gbr. 1, jumlah keseluruhan 918 data tersebut, analisis pada distribusi kelas target (HeartDisease) menunjukkan proporsi yang sangat memadai dan seimbang untuk pelatihan mesin. Terdapat sebanyak 508 pasien (55,3%) yang terdiagnosis memiliki indikasi penyakit kardiovaskular (Kelas 1), dan 410 pasien (44,7%) berada dalam kondisi normal (Kelas 0). Keseimbangan distribusi kuantitatif antar kelas menunjukkan proporsi yang relative seimbang. Visualisasi dari distribusi kelas target tersebut dapat dilihat dengan lebih jelas pada grafik batang di Gbr 2 berikut.

Gbr. 2 — Distribusi Kelas Target (HeartDisease)



Gbr. 2 — Grafik Bar Chart jumlah pasien berdasarkan kelas target. 508 terindikasi penyakit (1), 410 normal (0).

Gbr 2. Grafik Bar jumlah perbandingan data pasien berdasarkan kelas target Heart Disease (1: Terindikasi Penyakit, 0: Normal).

Merujuk pada visualisasi di Gbr. 2, keseimbangan proporsi antar kelas ini memberikan fondasi komputasi yang kuat. Kondisi tersebut memastikan bahwa algoritma *machine learning* dapat dilatih untuk mengenali pola dari kedua kondisi medis secara optimal, tanpa mengalami kendala bias kelas mayoritas (*class imbalance*) yang sering kali mendistorsi akurasi hasil prediksi pada sistem medis.

B. Hasil Eksplorasi dan Pra-pemrosesan Data

Hasil analisis eksplorasi data (EDA) mengungkap sejumlah pola kuantitatif yang signifikan secara klinis. Nilai korelasi tersebut, beserta hubungan menyeluruh antar fitur klinis lainnya, direpresentasikan secara visual melalui matriks korelasi pada Gbr 3 berikut.

Gbr. 3 — Matriks Korelasi Pearson



Gbr. 3 — Matriks Korelasi Pearson antara fitur medis dengan variabel target penyakit jantung. Warna merah = korelasi positif, biru = korelasi negatif.

Gbr 3. Matriks Korelasi (Heatmap) korelasi Pearson antar fitur medis dengan variabel target penyakit jantung.


Analisis korelasi pada Gbr 3 di atas, variabel *Oldpeak* (0.40) dan *Usia* (0.28) menunjukkan korelasi positif tertinggi terhadap indikasi penyakit jantung, yang menegaskan bahwa semakin tinggi tingkat depresi ST dan semakin tua usia pasien, probabilitas terdiagnosis penyakit tersebut akan semakin besar. Sebaliknya, kapasitas detak jantung maksimal atau *MaxHR* (-0.40) memiliki korelasi negatif paling signifikan, memvalidasi secara klinis bahwa rendahnya batas maksimal detak jantung saat beraktivitas berbanding lurus dengan tingginya risiko kardiovaskular. Selain itu, *heatmap* ini juga mengungkap korelasi negatif yang logis antar-prediktor, yakni antara *Usia* dan *MaxHR* (-0.38), yang mengonfirmasi fakta biologis bahwa kapasitas detak jantung manusia menurun seiring bertambahnya usia. Secara keseluruhan, dapat disimpulkan bahwa *Oldpeak* dan *MaxHR* merupakan dua prediktor numerik yang paling dominan secara statistik dalam menentukan label risiko penyakit jantung pada dataset ini.

Tahapan dilanjutkan ke proses pra-pemrosesan data. Pada tahap ini, transformasi data kategorikal melalui teknik penyandian (*encoding*) berhasil mendigitalisasi teks rekam medis. Sementara itu, proses standarisasi sukses menormalkan distribusi varians pada fitur numerik yang memiliki satuan berbeda. Melalui kedua proses tersebut, keseluruhan data telah mencapai tingkat homogenitas metrik yang siap untuk dikomputasi oleh model algoritma.

C. Hasil Permodelan Data

Komparasi metrik antara dua skenario pemodelan menunjukkan perbedaan efisiensi komputasi yang sangat krusial. Pada Skenario A, penggunaan keseluruhan 11 atribut medis secara mentah menghasilkan waktu pelatihan yang lebih lambat dan memunculkan indikasi noise dari fitur dengan korelasi rendah. Sebaliknya, eksperimen Skenario B yang menerapkan teknik Recursive Feature Elimination (RFE) berhasil memangkas redundansi tersebut dengan menyeleksi fitur-fitur yang paling determinan, seperti usia, tipe nyeri dada, kadar kolesterol, dan MaxHR. Nilai kontribusi atau tingkat signifikansi dari fitur-fitur yang diseleksi pada Skenario B ini divisualisasikan lebih rinci pada Gbr 4 berikut.

Gbr. 4 — Grafik Feature Importance



Gbr. 4 — Grafik Feature Importance yang menunjukkan hasil dari proses seleksi fitur menggunakan XGBoost.

Gbr 4. Grafik Tingkat Kepentingan Fitur dari atribut medis terpilih


Grafik pada Gbr 4, berdasarkan grafik *Feature Importance*, fitur *ST_Slope_Up* secara ekstrem mendominasi keputusan model XGBoost dengan bobot kontribusi mendekati 0.6. Tingkat kepentingan ini terpaut sangat jauh dari fitur di urutan kedua, *ChestPainType_ASY* (<0.1), maupun belasan atribut medis lainnya yang hanya memberikan dampak marginal. Kesimpulannya, model klasifikasi ini sangat bergantung pada indikator elektrokardiogram spesifik (*ST_Slope_Up*) sebagai parameter paling penentu untuk memprediksi risiko penyakit jantung.

Pendekatan seleksi fitur menyoroti dengan jelas atribut mana saja yang paling berpengaruh terhadap performa model. Secara keseluruhan, hasil pengujian membuktikan bahwa Skenario B tidak hanya efisien dalam mereduksi dimensi data, tetapi juga berhasil menjaga nilai presisi secara optimal karena model terhindar dari bias variabel yang tidak relevan.

D. Hasil Segmentasi Pasien (Klastering)

Pendekatan yang digunakan untuk menangani tingginya variasi profil klinis pasien, yaitu dengan menggunakan segmentasi unsupervised learning menunjukkan hasil pemisahan spasial yang tajam. Berdasarkan evaluasi matematis pada kurva Elbow Method, terlihat penurunan inersia yang melandai pada titik $K=3$. Hal ini divalidasi secara empiris oleh grafik *Silhouette Score* yang mencapai puncak tertinggi pada nilai K yang sama. Proses dan konfirmasi penentuan jumlah kluster optimal berdasarkan perpaduan metode tersebut ditunjukkan secara visual pada Gbr 5.


Gbr. 5 — Kurva Elbow dan Grafik Silhouette Score



Gbr 5. Visualisasi Kurva Elbow dan Grafik Silhouette Score

Berdasarkan hasil pemantauan grafik pada Gbr. 5, penentuan jumlah kluster (k) yang paling optimal dievaluasi menggunakan dua metrik komputasi. Pada kurva *Elbow* di sebelah kiri, tingkat penurunan inersia (jarak antar-data dalam kluster) terlihat mulai melandai pada titik $k=3$. Indikasi awal ini kemudian divalidasi secara meyakinkan oleh grafik *Silhouette Score* di sebelah kanan. Pada grafik tersebut, metrik evaluasi mencapai titik puncak tertinggi secara eksak pada nilai $k=3$, yang secara tegas ditandai dengan ikon bintang merah. Kesimpulannya, perpaduan evaluasi dari kedua metode tersebut memberikan justifikasi matematis yang kuat bahwa pembagian pasien ke dalam tiga kluster ($k=3$) merupakan konfigurasi yang paling optimal untuk pemodelan data ini. Batas pemisahan spasial dari ketiga kelompok profil risiko tersebut dapat dicermati pada Gbr 6.

Gbr. 6 — Plot Sebaran PCA 2 Dimensi



Gbr 6. Plot Sebaran Principal Component Analysis (PCA) 2 Dimensi

Plot PCA yang diilustrasikan pada Gbr. 6 di atas, hasil pengklasteran dari algoritma K-Means ($k=3$) diproyeksikan ke dalam ruang dua dimensi menggunakan teknik reduksi dimensi *Principal Component Analysis* (PCA). *Scatter plot* tersebut secara visual memetakan persebaran profil pasien ke dalam tiga batas spasial yang merepresentasikan tingkat risiko penyakit jantung:

1) *Klaster 0 (Risiko Rendah)*: Direpresentasikan oleh titik berwarna hitam, terlihat mengelompok secara terpisah dan padat di sisi kiri bidang (area nilai PC1 negatif).

2) *Klaster 1 (Risiko Moderat)*: Direpresentasikan oleh titik berwarna oranye, yang menyebar di area tengah hingga kanan bidang.


3) *Klaster 2 (Risiko Kritis)*: Direpresentasikan oleh titik berwarna merah, yang cenderung menyebar beriringan dengan kluster oranye di sisi kanan bidang (area nilai PC1 positif).

Secara keseluruhan, visualisasi persebaran PCA 2D ini mengonfirmasi bahwa pendekatan K-Means mampu membentuk batas pemisahan kluster yang terstruktur. Meskipun terdapat sedikit irisan (*overlapping*) secara visual antara kelompok risiko moderat dan kritis, kelompok pasien sehat (risiko rendah) berhasil dipisahkan secara sangat tegas. Pola sebaran ini menegaskan bahwa karakteristik klinis pasien pada setiap kluster memiliki homogenitas internal yang kuat, sehingga ekstraksi profil ini valid dan siap digunakan untuk mendukung rekomendasi intervensi medis yang lebih personal.

E. Hasil Klasifikasi dan Evaluasi Model

Integrasi label klastering ke dalam arsitektur klasifikasi hibrida terbukti secara signifikan mendongkrak ketajaman prediksi model supervised learning. Evaluasi silang pada data uji menunjukkan bahwa algoritma XGBoost mendominasi performa dengan tingkat Akurasi tertinggi, mengungguli Random Forest dan Logistic Regression. Mengingat penelitian ini memprioritaskan metrik *Recall* untuk menekan angka *False Negatives* di ranah medis, XGBoost mencatatkan performa yang sangat memuaskan dibandingkan dengan algoritma lainnya. Perbandingan menyeluruh mengenai metrik evaluasi dari masing-masing model yang diuji disajikan secara visual pada Gbr 7.


Gbr. 7 — Komparasi Metrik Kinerja Semua Model



Gbr 7. Diagram Batang komparasi Confusion Matrix Logistic Regression, Random Forest, dan XGBoost.

Berdasarkan grafik komparasi pada Gbr 7, komparasi kinerja antara model *Logistic Regression*, *Random Forest*, dan *XGBoost* dievaluasi menggunakan empat metrik utama, yaitu Akurasi, Presisi, Recall, dan *F1-Score*. Merujuk pada data tersebut, *Logistic Regression* secara keseluruhan mendominasi performa klasifikasi dengan mencatatkan nilai tertinggi pada metrik Akurasi (0.8967), *Recall* (0.9216), dan *F1-Score* (0.9082). Sementara itu, model *XGBoost* menunjukkan keunggulan spesifik pada metrik Presisi dengan skor tertinggi (0.8980), yang mengindikasikan kemampuannya dalam meminimalkan *false positive* (pasien sehat yang keliru diprediksi sakit). Namun, mengingat deteksi penyakit medis umumnya sangat memprioritaskan metrik *Recall* untuk menekan angka *false negative* yang berisiko fatal, performa *Logistic Regression* pada pengujian ini terlihat paling optimal karena memiliki tingkat sensitivitas yang melampaui kedua algoritma lainnya. Rincian mengenai proporsi klasifikasi prediksi tersebut ditunjukkan pada Gbr 8.

Gbr. 8 — Confusion Matrix XGBoost



Gbr 8. Visualisasi Confusion Matrix dari model XGBoost


Rincian data pada Gambar 8 di atas, Keseluruhan proporsi tebakan ini secara matematis menghasilkan tingkat Akurasi sebesar 0.8696 dan Presisi yang tergolong tinggi (0.8980). Namun, dalam konteks implementasi klinis, keberadaan 14

kasus *False Negative* yang berujung pada skor *Recall* sebesar 0.8627 perlu menjadi catatan penting, mengingat kegagalan sistem dalam mendeteksi pasien yang sebenarnya menderita penyakit jantung dapat berimplikasi pada risiko medis yang fatal.

F. Hasil Klasifikasi dan Evaluasi Model

Untuk membedah mekanisme pengambilan keputusan dari algoritma *XGBoost*, analisis SHapley Additive exPlanations (SHAP) menyajikan justifikasi klinis yang sangat transparan. Plot ringkasan (Summary Plot) SHAP memperlihatkan bahwa kemiringan segmen ST tipe Flat dan tipe nyeri dada Asymptomatic menyumbang dorongan probabilitas positif yang paling dominan terhadap terdiagnosisnya penyakit kardiovaskular. Sebaliknya, titik data dengan nilai kapasitas detak jantung maksimum (MaxHR) yang tinggi secara konsisten berkumpul di area negatif pada plot, yang secara fungsional menekan probabilitas pasien terindikasi sakit. Visualisasi menyeluruh mengenai distribusi pengaruh dari tiap-tiap fitur ini dapat diamati pada Gbr. 9 berikut.

Gbr. 9 — SHAP Summary Plot



Gbr 9. Grafik SHAP Summary Plot


Mengacu pada sebaran data yang tergambar pada Gbr 9. Visualisasi *SHAP Summary Plot* berfungsi mengurai sifat "kotak hitam" (*black-box*) algoritma *XGBoost* dengan memetakan rata-rata absolut dampak marginal setiap fitur (*Mean [SHAP]*) terhadap prediksi global. Berdasarkan besaran nilai SHAP, fitur *ST Slope Up* mendominasi secara ekstrem sebagai prediktor paling determinan (skor mendekati 1.2), disusul oleh *ChestPainType_ASY* (~0.9). Sementara itu, fitur medis lainnya hanya memberikan kontribusi yang jauh lebih minor (<0.6). Pendekatan SHAP ini secara transparan memvalidasi bahwa bobot komputasi prediktif model telah selaras dengan prioritas indikator klinis kardiovaskular di dunia nyata.

V. IMPLEMENTASI SISTEM

Bab ini membahas realisasi teknis model *machine learning* ke dalam antarmuka berbasis web. Sistem dibangun menggunakan bahasa pemrograman Python dengan framework Streamlit dan dijalankan dalam lingkungan pengembangan yang terintegrasi (Jupyter/VS Code). Antarmuka didesain dengan tema gelap (*dark theme*) untuk meningkatkan fokus pengguna terhadap data klinis yang disajikan.

A. Modul Menu Main

Sistem diimplementasikan dengan struktur navigasi sidebar yang intuitif untuk memisahkan setiap tahapan analisis. Halaman utama (*main*) pada aplikasi ini menyajikan "*Hero Section*" yang memperkenalkan tujuan utama dari sistem, yaitu prediksi dan segmentasi risiko penyakit jantung menggunakan teknik *Data Mining*. Tampilan visual dari antarmuka halaman utama tersebut dapat dilihat pada Gbr. 10 berikut.




Gbr. 10 Tampilan Utama (Main) aplikasi prediksi risiko penyakit jantung

Tampilan antarmuka yang ditampilkan pada Gambar 3 di atas, sistem juga menyediakan ringkasan indikator kunci (*key indicators*) pada bagian bawah halaman. Fitur pemaparan ringkasan ini dirancang untuk memudahkan tenaga medis dalam melihat informasi esensial secara instan, yang mencakup total data pasien (918 observasi), jumlah fitur klinis yang diproses (11 fitur), serta algoritma model terbaik yang aktif beroperasi pada sistem (XGBoost). Desain antarmuka yang informatif ini memastikan pengguna mendapatkan konteks yang jelas sebelum mengeksplorasi modul analisis yang lebih mendalam.


B. Modul Menu Beranda dan Tinjauan Dataset

Setelah memahami indikator kunci pada halaman utama, pengguna dapat beralih ke menu beranda (*Home*). Halaman ini merupakan antarmuka yang dirancang khusus untuk menyajikan ringkasan statistik komprehensif dari dataset yang digunakan dalam pemodelan. Ringkasan tersebut mencakup informasi mengenai total rekam medis pasien, jumlah fitur prediktor beserta deskripsi lengkapnya, hingga proporsi distribusi kelas target yang divisualisasikan secara jelas dalam bentuk diagram lingkaran (*pie chart*). Detail dari tampilan antarmuka ringkasan data ini dapat dilihat pada Gbr. 11 berikut.



Gbr. 11 Tampilan Menu Utama (Main) yang menyajikan ringkasan dataset, deskripsi fitur, dan distribusi kelas target.

Selain menyajikan profil data seperti yang terlihat pada Gambar 11 di atas, menu beranda ini juga dirancang untuk memberikan transparansi metodologi. Dengan menggulir halaman lebih ke bawah, antarmuka akan menampilkan enam tahapan standar CRISP-DM, mulai dari fase *Business Understanding* hingga *Deployment*. Pemaparan alur ini bertujuan agar pengguna dapat memahami secara komprehensif proses analisis di balik model prediksi yang mereka gunakan. Sebagai pelengkap, halaman ini juga dilengkapi dengan fitur pratinjau (*preview*) berupa tabel yang memuat 10 sampel data pertama dari dataset rekam medis pasien. Susunan antarmuka untuk tahapan metodologi dan pratinjau data ini diilustrasikan pada Gbr 12.




Gbr. 12 Tampilan lanjutan menu beranda (*Home*) yang memaparkan tahapan metodologi CRISP-DM dan tabel pratinjau sampel data pasien.

Melalui kehadiran fitur pratinjau pada Gbr 12 tersebut, pengguna dapat melihat secara langsung wujud representasi data klinis yang sedang diolah oleh sistem. Transparansi informasi dari hulu ke hilir pada menu *Home* ini diharapkan mampu membangun pemahaman dan kepercayaan tenaga medis terhadap integritas sistem, sebelum mereka melangkah ke tahap eksplorasi visual maupun prediksi pada menu-menu berikutnya.


C. Modul Menu Eksplorasi Data (EDA)

Menu menu *Eksplorasi Data Analysis* (EDA) dapat diakses oleh pengguna untuk melakukan peninjauan dataset secara mendalam melalui kontrol interaktif "Data Asli" dan "Data Setelah *Preprocessing*". Pada tahap ini, antarmuka merangkum statistik deskriptif secara menyeluruh dan menampilkan hasil deteksi anomali pada segmen "Nilai Nol & Missing". Sebagai contoh temuan, sistem berhasil mengidentifikasi 172 observasi dengan nilai kolesterol nol. Untuk menjaga integritas model, anomali tersebut langsung ditangani melalui teknik imputasi menggunakan nilai median (237.0). Hasil rekapitulasi penanganan data awal ini ditunjukkan pada Gbr 13.




Gbr. 13 Tampilan menu *Eksplorasi Data* (EDA) yang menyajikan kontrol *preprocessing*, statistik deskriptif, serta penanganan nilai nol dan kosong .

Selain validasi anomali, sistem juga menyediakan visualisasi dinamis berbasis menu *dropdown* untuk mengidentifikasi pola hubungan antara fitur prediktor dengan kelas target (*HeartDisease*), sebagaimana diilustrasikan pada Gbr 14 berikut.



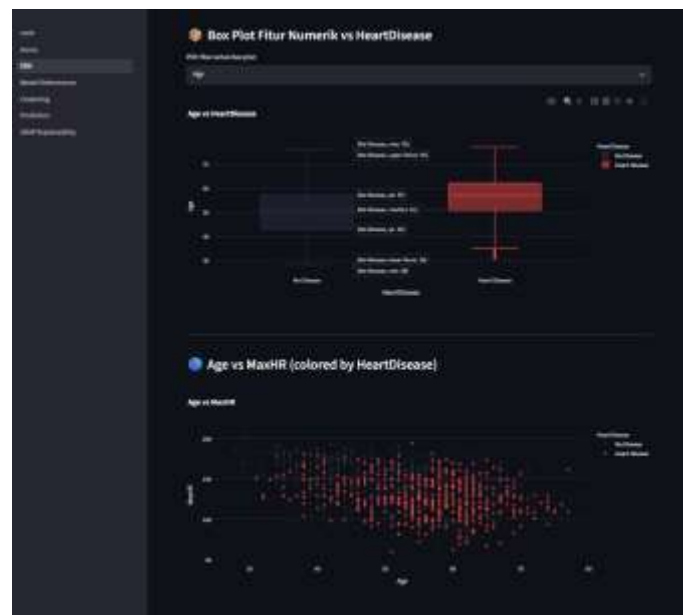
Gbr. 14 Tampilan lanjutan menu EDA isualisasi dinamis distribusi fitur numerik dan kategorikal pada antarmuka EDA.

Melalui visualisasi interaktif pada Gbr. 14, karakteristik klinis pasien dapat diinterpretasikan dengan jelas. Pada "Distribusi Fitur Numerik", histogram (misalnya pada fitur *Age*) membedakan rentang usia pasien normal dan terindikasi sakit. Sementara itu, pada "Distribusi Fitur Kategorikal", penggunaan diagram batang terkomposisi (*stacked bar chart*) mempertegas perbedaan prevalensi demografis, seperti tingginya rasio risiko pada laki-laki (M) dibandingkan perempuan (F). Evaluasi hubungan matematis antar-variabel klinis dilakukan melalui matriks korelasi (*heatmap*) sebagaimana ditunjukkan pada Gbr. 15



Gbr. 15 Tampilan lanjutan menu *Eksplorasi Data* (EDA) yang menyajikan matriks korelasi (*heatmap*) antar-variabel klinis.

Melalui visualisasi pada Gbr. 15, dapat diidentifikasi secara instan fitur-fitur numerik yang memiliki korelasi terkuat terhadap indikasi penyakit. Sebagai temuan utama, sistem mengonfirmasi adanya korelasi negatif yang signifikan pada detak jantung maksimal (*MaxHR*), sebaliknya korelasi positif terlihat pada fitur *Oldpeak* dan Usia (*Age*). Untuk membedah sebaran data dan interaksi variabel secara lebih mendalam, sistem juga menyediakan visualisasi *box plot* dan diagram pencar (*scatter plot*) seperti yang diilustrasikan pada Gbr. 16.




Gbr. 16 Rincian interaktif *box plot* untuk deteksi pencilan dan *scatter plot* untuk analisis interaksi multi-variabel.

Berdasarkan hasil visualisasi pada Gambar 16, *box plot* efektif dalam mendeteksi keberadaan penciran (*outlier*) sekaligus menyoroti perbedaan nilai kuartil dan median antara kelompok pasien sehat dan sakit. Sementara itu, pemetaan multi-variabel pada *scatter plot* contohnya pada interaksi antara Usia dan *MaxHR* mampu memperlihatkan pola pengelompokan yang jelas berdasarkan label penyakit. Rangkaian temuan komprehensif dari proses eksplorasi visual ini memberikan justifikasi kuat bahwa model prediktif nantinya dibangun di atas landasan data yang telah tervalidasi, baik secara statistik maupun logika klinis.

D. Modul Menu Model Performance

Menu *Model Performance* dirancang sebagai dasbor analitik untuk memvalidasi dan membandingkan keandalan algoritma *machine learning* yang digunakan dalam sistem. Pada bagian awal, sistem menyajikan tayangan komparasi keseluruhan model (Logistic Regression, Random Forest, dan XGBoost) melalui tabel ringkasan dan diagram batang (*bar chart*). Visualisasi ini membandingkan metrik evaluasi krusial seperti *Accuracy*, *F1-Score*, *ROC-AUC*, *Precision*, dan *Recall*. Pendekatan komparatif ini dirancang untuk memberikan pandangan tingkat tinggi (*high-level overview*) secara transparan kepada praktisi medis mengenai model mana yang memiliki kinerja generalisasi terbaik. Tampilan antarmuka untuk komparasi metrik ini dapat dilihat pada Gbr 16.



Gbr 17. Tampilan menu model performance confusion matrix (Akurasi, *F1-Score*, dan *ROC-AUC*)


Guna memfasilitasi analisis yang lebih mendalam, antarmuka juga menyediakan fitur "Detail Per Model" yang disajikan dalam bentuk tab interaktif, sebagaimana diilustrasikan pada Gbr. 17.



Gbr 18. Rincian performa spesifik model (contoh: *Logistic Regression*) *Confusion Matrix* dan Kurva ROC

Berdasarkan panel interaktif pada Gbr. 18 di atas, pengguna dapat meninjau rincian performa dari masing-masing algoritma secara spesifik. Halaman ini memvisualisasikan matriks kebingungan (*confusion matrix*) yang memetakan secara detail jumlah tebakan benar (*True Positive / True Negative*) dan tebakan salah (*False Positive / False Negative*) antara prediksi sistem dengan data aktual. Selain itu, terdapat visualisasi kurva *Receiver Operating Characteristic* (ROC) yang memperlihatkan kemampuan model dalam membedakan antara kelas pasien sehat dan pasien terindikasi penyakit jantung berdasarkan area di bawah kurva (AUC).

Melengkapi transparansi pengambilan keputusan prediktif, modul ini juga memuat grafik tingkat kepentingan fitur (*feature importance*). Visualisasi diagram batang horizontal ini secara berurutan memeringkatkan 15 atribut medis yang paling dominan memengaruhi hasil prediksi model klasifikasi. Detail pemeringkatan atribut tersebut ditunjukkan pada Gbr. 19 berikut.



Gbr 19. Visualisasi *Feature Importance*

Merujuk pada grafik di Gambar 18, terlihat jelas kontribusi masing-masing variabel terhadap keputusan model. Sebagai contoh, fitur klinis seperti kemiringan segmen ST (*ST_Slope_Up*, *ST_Slope_Flat*) dan tipe nyeri dada asimtomatik (*ChestPainType_ASY*) memiliki bobot kepentingan tertinggi. Keberadaan grafik interpretasi ini sangat vital untuk membuktikan secara empiris bahwa pola matematis yang dipelajari oleh model komputasi telah sejalan dengan logika dan literatur patologi klinis yang mapan.


E. Modul Menu Clustering

Menu Clustering dirancang khusus untuk melakukan segmentasi data rekam medis pasien menggunakan pendekatan unsupervised learning melalui algoritma K-Means. Pada tahap awal evaluasi, sistem menyediakan visualisasi matematis untuk menentukan jumlah kluster (k) yang paling optimal. Antarmuka menampilkan kurva Elbow yang mengukur penurunan inersia, bersisian dengan grafik Silhouette Score. Berdasarkan hasil komputasi, sistem secara otomatis merekomendasikan pembagian pasien ke dalam tiga kelompok utama (k=3). Rekomendasi ini ditandai oleh tercapainya puncak tertinggi pada grafik Silhouette Score menggunakan penanda bintang merah. Visualisasi dari proses evaluasi penentuan jumlah kluster tersebut dapat dilihat pada Gbr. 20 berikut.




Gbr. 20 Visualisasi Kurva Elbow dan grafik *Silhouette Score*

Setelah penentuan jumlah kluster optimal divalidasi, langkah selanjutnya adalah memahami bentuk pemisahan kelompok pasien tersebut. Untuk mengakomodasi kebutuhan ini, antarmuka menyediakan fitur visualisasi spasial dua dimensi sebagaimana ditunjukkan pada Gambar 20



Gbr. 21 Plot sebaran *Principal Component Analysis* (PCA) dua dimensi

Merujuk pada plot sebaran di Gambar 21, teknik reduksi dimensi *Principal Component Analysis* (PCA) diterapkan untuk memetakan distribusi profil pasien ke dalam ruang dua dimensi (PC1 dan PC2). Diagram pencar (*scatter plot*) interaktif ini mengimplementasikan pengodean warna seperti hijau, merah, dan biru guna membedakan batas spasial secara tegas antara Klaster 0, Klaster 1, dan Klaster 2. Sebagai tahap akhir dari analisis segmentasi, antarmuka menyajikan dasbor analitik komprehensif yang rinciannya dapat diamati pada Gbr. 22.




Gbr. 22 Profil klinis dan prevalensi penyakit jantung per kluster.

Berdasarkan visualisasi pada Gbr. 22 di atas, sistem menampilkan tabel "Profil Cluster" yang mengagregasi nilai rata-rata dari berbagai parameter klinis seperti Usia (*Age*), tekanan darah istirahat (*RestingBP*), dan kadar kolesterol untuk masing-masing kelompok. Guna mengonversi data agregasi tersebut menjadi konteks klinis yang bermakna, modul ini juga dilengkapi dengan diagram batang "Prevalensi Penyakit Jantung per Cluster". Melalui visualisasi bergradasi warna ini, tenaga medis dapat dengan mudah melihat tingkat persentase risiko kardiovaskular pada setiap sub-populasi. Sebagai contoh temuan, Klaster 1 secara empiris teridentifikasi memiliki tingkat prevalensi tertinggi dengan persentase risiko mencapai 57,00%.


F. Modul Menu Prediction

Menu *Prediction* menyediakan formulir interaktif untuk memasukkan parameter rekam medis pasien baru. Penggunaan elemen *slider* dan *dropdown* pada antarmuka ini dirancang untuk meminimalisasi kesalahan ketik (*human error*). Pada tahap ini, pengguna juga diberikan keleluasaan untuk memilih algoritma prediktif (misalnya XGBoost) yang akan mengeksekusi data tersebut, sebagaimana ditunjukkan pada Gbr 22.



Gbr 22. Antarmuka formulir "Prediksi Risiko Penyakit Jantung" untuk input parameter klinis dan pemilihan model klasifikasi.

Setelah dieksekusi, sistem secara instan memproses input dan menampilkan persentase probabilitas risiko pasien melalui gauge chart bergradasi warna. Untuk memperkuat tingkat kepercayaan (trust) tenaga medis, luaran ini langsung diintegrasikan dengan grafik kontribusi fitur berbasis SHAP. Visualisasi dinamis ini mengurai secara transparan parameter medis spesifik milik pasien yang berfungsi menekan (Decrease Risk) atau mendorong (Increase Risk) probabilitas penyakit. Rincian hasil prediksi dan justifikasi klinis personal ini dapat diamati pada Gbr. 22 berikut.



Gbr 22. Hasil prediksi *real-time*

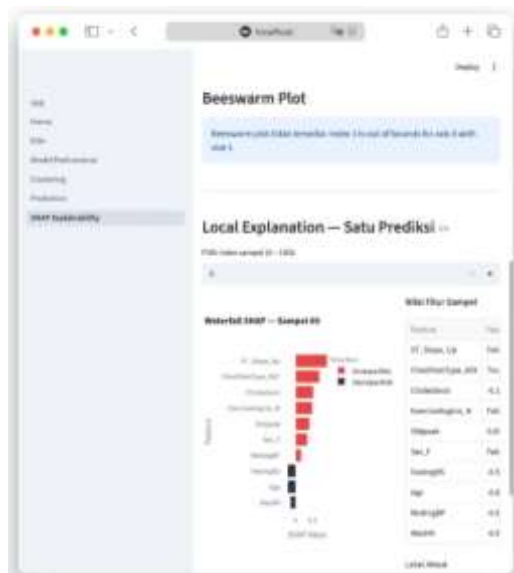
G. Modul Shap Expalanation

Modul *SHAP Explainability* dirancang secara khusus untuk mengatasi sifat "kotak hitam" (*black-box*) dari algoritma *machine learning* kompleks seperti XGBoost. Modul ini bertujuan memberikan transparansi keputusan, baik pada tingkat makro maupun mikro. Pada tingkat makro, antarmuka menyajikan analisis "*Global Feature Importance*" yang mengukur besaran rata-rata absolut nilai SHAP (*Mean |SHAP|*) dari keseluruhan dataset. Visualisasi diagram batang horizontal bergradasi warna ini secara komprehensif memeringkatkan fitur-fitur yang paling berpengaruh secara umum terhadap prediksi model. Tampilan analisis tingkat makro tersebut dapat dilihat pada Gbr 23 berikut.



Gbr 23. Tampilan antarmuka Global Feature Importance berbasis nilai Mean Absolute SHAP

Merujuk pada grafik di Gbr. 23, terlihat jelas bahwa fitur seperti *ST_Slope_Up* dan *ChestPainType_ASY* mendominasi hierarki. Temuan ini memberikan konfirmasi global bahwa model memprioritaskan indikator-indikator klinis yang memang terbukti secara medis relevan dengan risiko kardiovaskular. Beralih ke analisis tingkat mikro, sistem menyediakan fitur "*Local Explanation — Satu Prediksi*" yang memungkinkan tenaga medis menelusuri justifikasi algoritma pada skala pasien secara individu. Melalui kontrol indeks sampel interaktif, pengguna dapat memanggil data spesifik untuk dianalisis, sebagaimana diilustrasikan pada Gbr. 24.



Gbr 24. Tampilan fitur *Local Explanation* yang menyajikan *Waterfall SHAP Plot* dan tabel nilai fitur interaktif

Berdasarkan antarmuka pada Gambar 24, sistem merender *Waterfall SHAP Plot* yang membedah arah kontribusi dari masing-masing parameter secara detail. Batang berwarna merah merepresentasikan fitur yang mendorong peningkatan probabilitas risiko (*Increase Risk*), sedangkan batang gelap merepresentasikan fitur yang menekan probabilitas risiko (*Decrease Risk*). Guna melengkapi utilitas klinisnya, visualisasi ini disandingkan langsung dengan tabel "Nilai Fitur Sampel" serta informasi "Label Aktual" dari pasien, yang rinciannya ditunjukkan pada Gbr. 25.



Gbr 25. Interpretasi lokal kontribusi fitur dan label aktual pasien.

Melalui integrasi informasi seperti yang terlihat pada Gbr. 25 di atas, komparasi langsung antara rasionalisasi model dan kondisi pasien yang sebenarnya dapat dilakukan dengan mudah. Pendekatan interpretasi komprehensif ini memastikan bahwa setiap inferensi komputasional yang dihasilkan oleh sistem dapat divalidasi, dilacak akar penyebabnya, dan diselaraskan dengan rekam medis aktual (*ground truth*) sebelum digunakan sebagai landasan pengambilan keputusan klinis.

VI. KESIMPULAN

Penelitian ini berhasil mengembangkan dan memvalidasi arsitektur *machine learning* hibrida yang efektif dalam mengatasi kompleksitas dan heterogenitas data klinis pada prediksi penyakit jantung. Penggunaan *K-Means clustering* pada tahap pra-pemrosesan terbukti krusial dalam membentuk tiga segmen batas risiko spasial yang tegas, sehingga mempermudah algoritma klasifikasi mengenali pola dari kelompok populasi yang lebih homogen. Melalui mekanisme seleksi fitur (RFE), penelitian ini berhasil mereduksi dimensi data dan mengonfirmasi secara empiris bahwa indikator *ST_Slope_Up* dan *ChestPainType_ASY* merupakan variabel paling dominan dalam memprediksi risiko penyakit kardiovaskular.

Pada tahap evaluasi klasifikasi, algoritma *Logistic Regression* terbukti sebagai model paling ideal untuk implementasi medis dibandingkan *XGBoost* dan *Random Forest*. Dengan tingkat *Recall* tertinggi mencapai 92,16% dan Akurasi 89,67%, model ini mampu menekan angka *false negative* secara signifikan sebuah faktor kritis untuk menghindari kegagalan diagnosis pasien berisiko. Lebih lanjut, integrasi metode *Explainable AI* (XAI) melalui SHAP sukses mendobrak batasan *black-box*, memberikan justifikasi prediktif yang transparan dan selaras dengan literatur patologi

klinis. Pengembangan *pipeline* analitik ke dalam antarmuka *dashboard website (Streamlit)* membuktikan bahwa model komputasi yang kompleks dapat dijembatani menjadi instrumen praktis, *real-time*, dan interpretabel bagi tenaga kesehatan. Sebagai pengembangan ke depan, penelitian dapat memperluas pengujian arsitektur ini pada rekam medis elektronik (EMR) multisenter berskala lebih besar dan mengintegrasikan data klinis sekuensial (seperti rekam EKG *time-series*) untuk pemantauan pasien secara kontinu.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Ibu Wiyli Yustanti selaku dosen atas bimbingan, arahan, serta ilmu berharga yang diberikan selama proses penyelesaian penelitian ini. Ucapan terima kasih juga ditujukan kepada rekan-rekan mahasiswa program studi S2 atas diskusi dan lingkungan akademik yang suportif. Secara khusus, apresiasi tertinggi diberikan kepada seluruh anggota kelompok, pemilik NIM 004 dan NIM 016, atas dedikasi, kolaborasi, dan kerja keras yang solid dari awal hingga selesainya karya ini. Terakhir, terima kasih disampaikan kepada Tim JIEET yang telah meluangkan waktu untuk membuat dan menyediakan *template* penulisan ini, yang sangat membantu kelancaran penyusunan artikel

REFERENSI

- [1] B. A. Stark *dkk.*, "Global, Regional, and National Burden of Cardiovascular Diseases and Risk Factors in 204 Countries and Territories, 1990-2023," *JACC*, vol. 86, no. 22, hlm. 2167–2243, Des 2025, doi: 10.1016/j.jacc.2025.08.015.
- [2] "Report: cardiovascular diseases caused 1 in 3 global deaths in 2023," Institute for Health Metrics and Evaluation, Sep 2025. [Daring]. Tersedia pada: <https://www.healthdata.org/news-events/newsroom/news-releases/report-cardiovascular-diseases-caused-1-3-global-deaths-2023>
- [3] S. Nafisah, Novianti Nuril Inayah, dan Baharuddin Yusuf, "Literatur Review: Penyebab Dan Perkembangan Penyakit Jantung Koroner," *J. Forum Kesehat. Media Publ. Kesehat. Ilm.*, vol. 14, no. 1, hlm. 27–36, Agu 2024, doi: 10.52263/jfk.v14i1.254.
- [4] D.-I. Kasartzian dan T. Tsiampalis, "Transforming Cardiovascular Risk Prediction: A Review of Machine Learning and Artificial Intelligence Innovations," *Life*, vol. 15, no. 1, hlm. 94, Jan 2025, doi: 10.3390/life15010094.
- [5] C. Martins *dkk.*, "Identifying subgroups in heart failure patients with multimorbidity by clustering and network analysis," *BMC Med. Inform. Decis. Mak.*, vol. 24, no. 1, hlm. 95, Apr 2024, doi: 10.1186/s12911-024-02497-0.
- [6] G. Logabiraman, D. Ganesh, M. S. Kumar, A. V. Kumar, dan N. Bhardwaj, "Heart disease prediction using machine learning algorithms," *MATEC Web Conf.*, vol. 392, hlm. 01122, 2024, doi: 10.1051/mateconf/202439201122.
- [7] K. Cao *dkk.*, "Prediction of cardiovascular disease based on multiple feature selection and improved PSO-XGBoost model," *Sci. Rep.*, vol. 15, no. 1, hlm. 12406, Apr 2025, doi: 10.1038/s41598-025-96520-7.
- [8] M. D. Teja dan G. M. Rayalu, "Optimizing heart disease diagnosis with advanced machine learning models: a comparison of predictive performance," *BMC Cardiovasc. Disord.*, vol. 25, no. 1, hlm. 212, Mar 2025, doi: 10.1186/s12872-025-04627-6.
- [9] T. J. H. Mim, Md. M. Hassan, B. K. Paul, dan M. S. H. Mollah, "Machine Learning Approaches for Cardiovascular Disease Prediction: A Comparative Study," *Biomed. Mater. Devices*, Nov 2025, doi: 10.1007/s44174-025-00564-2.
- [10] A. H. Osman *dkk.*, "Breaking new ground in cardiovascular heart disease Diagnosis K-RFC: An integrated learning approach with K-means clustering and Random Forest classifier," *AIMS Math.*, vol. 9, no. 4, hlm. 8262–8291, 2024, doi: 10.3934/math.2024402.
- [11] C. M. Bhatt, P. Patel, T. Ghetia, dan P. L. Mazzeo, "Effective Heart Disease Prediction Using Machine Learning Techniques," *Algorithms*, vol. 16, no. 2, hlm. 88, Feb 2023, doi: 10.3390/a16020088.
- [12] A. Ogunpola, F. Saeed, S. Basurra, A. M. Albarak, dan S. N. Qasem, "Machine Learning-Based Predictive Models for Detection of Cardiovascular Diseases," *Diagnostics*, vol. 14, no. 2, hlm. 144, Jan 2024, doi: 10.3390/diagnostics14020144.
- [13] T. Banerjee dan Is. Paçal, "A systematic review of machine learning in heart disease prediction," *Turk. J. Biol.*, vol. 49, no. 5, hlm. 600–634, Okt 2025, doi: 10.55730/1300-0152.2766.
- [14] P. Liu, Z. Wang, N. Liu, dan M. A. Peres, "A scoping review of the clinical application of machine learning in data-driven population segmentation analysis," *J. Am. Med. Inform. Assoc.*, vol. 30, no. 9, hlm. 1573–1582, Agu 2023, doi: 10.1093/jamia/ocad111.
- [15] M. Sangeetha, "Enhancing Prediction of Heart Disease Using Hybrid Machine Learning Methods XGBoost and K-Means Clustering," 17 April 2025, *In Review*. doi: 10.21203/rs.3.rs-6446214/v1.
- [16] T. Chen dan C. Guestrin, "XGBoost: A Scalable Tree Boosting System," dalam *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco California USA: ACM, Agu 2016, hlm. 785–794. doi: 10.1145/2939672.2939785.
- [17] M. Dzaky, A. P. Kuncoro, dan R. Riyanto, "Optimizing XGBoost for Heart Disease Risk Classification Using Optuna and Random Search on the Behavioral Risk Factor Surveillance System (BRFSS) 2023 Dataset," *J. Appl. Inform. Comput.*, vol. 10, no. 1, hlm. 1015–1029, Feb 2026, doi: 10.30871/jaic.v10i1.11897.
- [18] L. Breiman, "Random Forests," *Mach. Learn.*, vol. 45, no. 1, hlm. 5–32, Okt 2001, doi: 10.1023/A:1010933404324.
- [19] D. Fania, I. Waspada, dan H. A. Wibawa, "Cardiovascular Disease Risk Prediction Using Random Forest, RFECV Feature Selection, and SHAP with Multisource Clinical Data Integration," *J. Tek. Inform. Jutif*, vol. 7, no. 1, hlm. 691–705, Feb 2026, doi: 10.52436/1.jutif.2026.7.1.5744.
- [20] D. W. Hosmer, S. Lemeshow, dan R. X. Sturdivant, *Applied Logistic Regression*, 1 ed. dalam Wiley Series in Probability and Statistics. Wiley, 2013. doi: 10.1002/9781118548387.
- [21] Muhammad Fitra Rhomadon, Wydyanto Wydyanto, A. Haidar Mirza, dan Nurul Huda, "Penerapan Algoritma Logistic Regression Untuk Memprediksi Penyakit Jantung," *J. Inform. Dan Teknologi Komput. JITEK*, vol. 5, no. 3, hlm. 133–147, Nov 2025, doi: 10.55606/jitek.v5i3.8105.
- [22] A. H. Osman *dkk.*, "Breaking new ground in cardiovascular heart disease Diagnosis K-RFC: An integrated learning approach with K-means clustering and Random Forest classifier," *AIMS Math.*, vol. 9, no. 4, hlm. 8262–8291, 2024, doi: 10.3934/math.2024402.

VII. KESIMPULAN

1. Link Dataset: <https://www.kaggle.com/fedesoriano/heart-failure-prediction?resource=download>
2. Link Aplikasi : https://heart-disease-prediction-app-wsq8hedxfivrnyg99n5rz.streamlit.app/SHAP_Explainability
3. Link Presentasi: <https://youtu.be/SCYuOCOmBTw>
4. Link Repository Project : <https://github.com/seriusman0/heart-disease-prediction-app>