

Sistem Prediksi Risiko **Penyakit Jantung**

Pendekatan Machine Learning Berbasis Klasterisasi dan Explainable AI

Oleh:

Seriusman Waruwu (25051905004) , Zaskhia Artina Isnalifah (25051905016)

Tugas Akhir Mata Kuliah Data Mining

Agenda Presentasi

- 1 Latar Belakang
- 2 Dataset & Eksplorasi
- 3 Metode Komputasi
- 4 Hasil Evaluasi
- 5 Demo Aplikasi

1. Latar Belakang & Urgensi

- 💡 **Konteks Medis:** Penyakit kardiovaskular memiliki risiko tinggi yang menuntut deteksi dini secara akurat dan presisi.
- 📦 **Masalah "Black-Box":** Algoritma machine learning kompleks (seperti XGBoost) umumnya beroperasi seperti kotak hitam dan sulit diinterpretasikan secara medis.
- 💡 **Solusi Penelitian:** Membangun model prediktif yang tidak hanya akurat secara matematis, tetapi juga transparan (Explainable AI) untuk menumbuhkan rasa percaya (trust) dari tenaga medis.



2. Karakteristik Dataset & Ekstraksi Pola

Dimensi & Validasi Data

Dataset terdiri dari 918 observasi rekam medis valid. Data ini telah melalui tahapan pra-pemrosesan (data preprocessing) yang ketat, meliputi pembersihan anomali, teknik imputasi data, serta proses standarisasi metrik untuk memastikan model menerima input yang homogen.

Dataset ini mencakup 11 fitur prediktor yang merepresentasikan kondisi medis pasien serta 1 label target.

Temuan Matriks Korelasi

Korelasi Positif: Tingkat depresi ST (Oldpeak) dan Usia berbanding lurus dengan peningkatan indikasi risiko penyakit jantung.

Korelasi Negatif: Kapasitas detak jantung maksimal (MaxHR) berbanding terbalik, mengonfirmasi penurunan toleransi kardiovaskular.

Deskripsi Atribut Dataset

Variabel	Tipe Data	Deskripsi Singkat
Age	Numerik	Usia pasien (dalam tahun).
Sex	Kategorikal	Jenis kelamin (M: Laki-laki, F: Perempuan).
ChestPainType	Kategorikal	Tipe nyeri dada (TA, ATA, NAP, ASY).
RestingBP	Numerik	Tekanan darah saat istirahat (mm Hg).
Cholesterol	Numerik	Kadar kolesterol serum (mm/dl).
FastingBS	Kategorikal	Gula darah puasa (1 jika > 120 mg/dl, 0 jika tidak).
RestingECG	Kategorikal	Hasil EKG saat istirahat (Normal, ST, LVH).
MaxHR	Numerik	Detak jantung maksimum yang dicapai.
ExerciseAngina	Kategorikal	Angina akibat olahraga (Y: Ya, N: Tidak).
Oldpeak	Numerik	Depresi ST akibat olahraga relatif terhadap istirahat.
ST_Slope	Kategorikal	Kemiringan segmen ST (Up, Flat, Down).
HeartDisease	Target	Indikasi penyakit (1: Positif sakit, 0: Normal).

3. Alur Metode Komputasi



Unsupervised Learning

Segmentasi profil pasien dilakukan menggunakan algoritma **K-Means**. Evaluasi jumlah kluster optimal divalidasi menggunakan kurva Elbow dan Silhouette Score.



Supervised Learning

Klasifikasi risiko dieksekusi melalui komparasi tiga algoritma prediktif: **Logistic Regression, Random Forest**, dan **XGBoost** untuk menemukan akurasi tertinggi.



Explainability


Mengimplementasikan algoritma **SHAP** (SHapley Additive exPlanations) guna mengurai dan memvisualisasikan kontribusi fitur secara transparan.

4. Hasil Evaluasi

Klasterisasi, Performa Model, dan Transparansi
Keputusan

Segmentasi Profil Risiko Pasien (PCA 2D)

- ✓ **Optimalisasi Klaster:** Evaluasi Silhouette Score memvalidasi $k=3$ sebagai konfigurasi jumlah klaster paling optimal.
- 🛡️ **Klaster 0 (Risiko Rendah):** Terlihat terpisah secara tegas dan padat di area negatif PC1, menandakan homogenitas data yang kuat.
- 💙 **Klaster 1 & 2 (Moderat & Kritis):** Menyebar berdampingan di area positif, menunjukkan transisi tingkat keparahan gejala klinis secara spasial.



Komparasi Performa Algoritma Klasifikasi




Berdasarkan evaluasi, Logistic Regression mendominasi metrik Akurasi dan Recall, menjadikannya andal dalam menekan angka False Negative. Sementara itu, model kompleks seperti XGBoost menunjukkan keunggulan spesifik pada presisi.

Global Feature Importance (SHAP)

Interpretasi Tingkat Makro

Grafik SHAP Summary Plot secara transparan membuktikan bahwa fitur elektrokardiogram **ST_Slope_Up** merupakan parameter prediktif yang paling determinan secara global.

- ✓ Fitur *ChestPainType_ASY* menyusul di urutan kedua.
- ✓ Validasi ini mengonfirmasi bahwa prioritas komputasi algoritma telah selaras sepenuhnya dengan literatur patologi kardiologi.



5. Demo Aplikasi

Implementasi Sistem Pendukung Keputusan Klinis
(SPKK)

Antarmuka Input & Interpretasi Personal



Formulir Real-Time

Dashboard dirancang interaktif untuk meminimalisasi human error saat proses input rekam medis pasien.



Local Explanation

Menggunakan Waterfall SHAP Plot untuk membedah justifikasi algoritma pada skala individu secara terperinci.



Arah Kontribusi

Memisahkan parameter yang mendorong peningkatan risiko (**merah**) dan penurunan risiko (**gelap**) secara dinamis.

The screenshot displays a web application for heart disease risk prediction. On the left is a sidebar menu with options: app, Home, EDA, Model Performance, Clustering, **Prediction** (highlighted), and SHAP Explainability. The main content area is titled 'Prediksi Risiko Penyakit Jantung' and includes a 'Deploy' button. Below the title is a prompt: 'Masukkan data pasien untuk mendapatkan prediksi risiko penyakit jantung.' The 'Data Pasien' section contains several input fields: 'Age (Usia)' with a slider set to 50; 'Cholesterol (mm/dl)' with a numeric input of 200; 'ExerciseAngina' with a dropdown set to 'Tidak (N)'; 'Sex (Jenis Kelamin)' with a dropdown set to 'M'; 'FastingBS (Gula darah puasa > 120 mg/dl)' with radio buttons set to 'Tidak (0)'; 'Oldpeak (ST depression)' with a numeric input of 0.00; 'ChestPainType' with a dropdown set to 'ATA'; 'RestingECG' with a dropdown set to 'Normal'; 'ST_Slope' with a dropdown set to 'Up'; 'RestingBP (mmHg)' with a numeric input of 120; 'MaxHR (Detak jantung maks)' with a slider set to 150; and 'Model Prediksi' with a dropdown set to 'XGBoost'. A large red button at the bottom is labeled 'Prediksi Sekarang'.

Kesimpulan

Seleksi Fitur

Mereduksi dimensi data dan membuktikan indikator **ST_Slope_Up** dan **ChestPainType_ASY** sebagai variabel paling dominan.

Klastering (K-Means)

Membentuk tiga segmen risiko pasien. Membuat data lebih homogen untuk memudahkan pengenalan pola oleh algoritma.

Model Klasifikasi Terbaik

Logistic Regression terbukti paling ideal dengan Recall 92,16% dan Akurasi 89,67%, krusial untuk menekan false negative. Performa ini sangat penting untuk menekan angka false negative (kegagalan deteksi pasien berisiko tinggi). (mengungguli XGBoost dan Random Forest)

Transparansi Model (SHAP)

Integrasi XAI melalui SHAP mendobrak batasan black-box. Setiap prediksi dapat dijelaskan dan divalidasi sesuai literatur medis.

Implementasi Sistem (Streamlit)

Pipeline analitik diintegrasikan menjadi antarmuka dashboard web yang praktis, real-time, dan siap digunakan tenaga kesehatan.